




PREDICCIÓN DE CANCELACIÓN DE RESERVAS HOTELERAS

Daniel García Nilo

Master en Data Science & IA

¿QUÉ PROBLEMA QUEREMOS RESOLVER?

Las cancelaciones de última hora pueden provocar habitaciones vacías y pérdida de ingresos.

El objetivo del proyecto es identificar, en el momento de la reserva, qué clientes presentan mayor riesgo de cancelación.

Datos principales

119390 resrvas
32 variables
2 hoteles
2015-2017


Nulos principales

children: 4
country: 448
agent: 16340
company: 112593

***Se detectaron 31.994 filas idénticas. No se eliminaron automáticamente porque el dataset no dispone de un identificador único de reserva, por lo que no podemos asegurar que sean errores y no reservas diferentes con las mismas características.**

Target: **is_canceled**

is_canceled = 0 reserva no cancelada
is_canceled = 1 reserva cancelada



LIMPIEZA Y DATA LEAKAGE

Data Leakage ocurre cuando utilizamos información que todavía no estaría disponible en el momento de realizar la predicción.

Variables excluidas por data leakage:

- reservation_status
- reservation_status_date
- assigned_room_type
- booking_changes
- days_in_waiting_list
- deposit_type

El objetivo es que el modelo utilice únicamente información que tendría sentido conocer al reservar.

TRATAMIENTO DE NULOS Y FEATURE ENGINEERING

Inputacion en nulos:

agent: "Sin_agente"

company: "Sin_empresa"

Country: "Desconocido"

children: Imputación con la mediana
dentro del pipeline

```
children    4
country      0
agent        0
company      0
Name: Nulos pendientes, dtype: int64
```

Feature Engineering

`total_guests` = adults + children + babies

`total_nights` = stays_in_week_nights +
stays_in_weekend_nights

Estas variables resumen mejor el tamaño del grupo y la duración total de la estancia.

INSIGHTS

¿Se cancela más en un tipo de hotel?



Resultado: City Hotel tiene un **41,5 %** de cancelaciones y Resort Hotel, un **26,0 %**. La diferencia no explica por sí sola la causa.

Acción: comenzar una prueba de recordatorios en City Hotel y medir si reduce cancelaciones.

¿Cambia la cancelación según el canal por el que llega la reserva?




Resultado: la cancelación pasa del **9,4 %** con 0-7 días al **60,0 %** con más de 180 días. En estos datos, más antelación se relaciona con más cancelaciones.

Acción: programar reconfirmaciones durante las esperas largas sin penalizar automáticamente a quien reserva con tiempo.

INSIGHTS

¿Cambia la cancelación según el canal de distribución o segmento de mercado?



Resultado: TA/TO registra **40,3 %**, frente a **16,8 %** de Direct; el segmento Groups alcanza **60,2 %**. Canal y segmento describen aspectos distintos de una reserva.

Acción: coordinar reconfirmaciones con agencias y responsables de grupos.

Undefined tiene solo 5 reservas en canal y 2 en segmento: se oculta en los gráficos, pero no se eliminan esas filas.

¿Hay meses con mayor tasa de cancelación?




Resultado: abril tiene la tasa más alta de TRAIN (**40,8 %**) y enero la menor (**30,5 %**). No todos los meses incluyen los mismos años; la diferencia no tiene por qué deberse solo a la época del año.

Acción: planificar el seguimiento por mes y comprobar si el patrón se repite con más datos.

PREPARACIÓN PARA MACHINE LEARNING

Train Ajuste



65%

Datos con los que aprenden los modelos durante la comparación.


Train Validación



16,3%

Periodo posterior para elegir modelo, configuración y threshold (umbral de decisión).

Test



18,6%

Periodo final, que no usamos para ninguna de esas decisiones.

Conjunto	Reservas	Llegadas desde	Hasta
TRAIN ajuste	77.698	2015-07-01	2016-12-25
TRAIN validación	19.494	2016-12-26	2017-04-30
TEST reservado	22.198	2017-05-01	2017-08-31

Preprocesamiento numérico

- Imputación de nulos con mediana
- Estandarización con StandardScaler

Preprocesamiento categórico

- Imputación de categorías desconocidas
- Conversión a variables numéricas mediante OneHotEncoder

MODELOS Y MÉTRICAS



Métrica	Qué significa	Cómo la usamos
ROC-AUC	Capacidad global de distinguir cancelación/no cancelación; 0,5 es similar al azar y 1 es separación perfecta	Comparamos la capacidad general y optimizamos hiperparámetros
Recall	Porcentaje de todas las cancelaciones reales que detectamos	Es especialmente importante para negocio: si es bajo, muchas cancelaciones pasan desapercibidas
Precision	De las reservas señaladas, qué proporción realmente cancela	Controla intervenciones sobre clientes que no iban a cancelar
F1	Resume el equilibrio entre Precision y Recall	Comprueba el compromiso entre ambas

	ROC-AUC	Precision	Recall	F1
Modelo · validación a 0,50				
Logística	0.872	0.722	0.732	0.727

	ROC-AUC	Precision	Recall	F1
Modelo · validación a 0,50				
Logística	0.872	0.722	0.732	0.727
Logística balanced	0.871	0.653	0.833	0.732
Random Forest	0.895	0.832	0.571	0.677
HistGradientBoosting	0.902	0.810	0.621	0.703

THRESHOLD Y SELECCIÓN DE MODELO

	ROC-AUC	Precision	Recall	F1
Modelo				
Random Forest	0.895	0.832	0.571	0.677
Random Forest optimizado	0.893	0.834	0.571	0.678
HistGradientBoosting	0.902	0.810	0.621	0.703
HistGradientBoosting optimizado	0.900	0.811	0.618	0.701




	Modelo	Threshold	ROC-AUC	Precision	Recall	F1	% reservas señaladas
0	Random Forest optimizado	0.300	0.893	0.718	0.778	0.746	39.730
1	HistGradientBoosting	0.300	0.902	0.762	0.753	0.757	36.221

Modelo final seleccionado: HistGradientBoosting

RESULTADOS FINALES EN TEST

	ROC-AUC	Precision	Recall	F1	% reservas señaladas
TEST final · umbral 0.30					
HistGradientBoosting	0.891	0.682	0.890	0.773	52.910




El modelo detecta aproximadamente 89 de cada 100 cancelaciones reales.

Sin embargo, la Precisión cae al **68,2 %**, por lo que existen falsas alarmas relevantes.

El modelo señala aproximadamente el **52,9 %** de las reservas en TEST, frente al **36,2 %** observado en validación.

El comportamiento cambia en el periodo futuro: aumenta considerablemente la detección de cancelaciones, pero también la carga operativa.

¿QUÉ ESTÁ APRENDIENDO EL MODELO?



Una mayor antelación suele aumentar el riesgo estimado.

Más peticiones especiales suelen asociarse con menor riesgo.


Solicitar parking aparece como una señal especialmente fuerte de menor riesgo.

*La elevada importancia de `required_car_parking_spaces` debe validarse antes de producción, comprobando que la variable esté disponible realmente en el momento de reservar.

SHAP absoluto medio	
Variable	
country	1.238
agent	0.909
required_car_parking_spaces	0.622
total_of_special_requests	0.585
lead_time	0.568
customer_type	0.447
market_segment	0.405
arrival_date_year	0.310

EJEMPLO DE PREDICCIÓN + CONCLUSIONES

Reserva de mayor riesgo:



HistGradientBoosting + threshold 0,30 ofrece el mejor equilibrio encontrado entre detección, precisión y volumen de alertas.

En TEST alcanza un Recall del 89,0 %, detectando gran parte de las cancelaciones reales.

El modelo debe utilizarse inicialmente para acciones de bajo coste, como recordatorios o reconfirmaciones.

RECOMENDACIONES

Priorizar las reservas de alto riesgo para aplicar acciones preventivas de forma selectiva.

Enviar recordatorios y solicitudes de confirmación a clientes con mayor probabilidad de cancelar.

Prestar especial atención a reservas con mucha antelación, al presentar una mayor tasa de cancelación.

Adaptar las acciones según hotel, segmento y canal, ya que el riesgo no es igual para todos los perfiles.

Usar el modelo como apoyo al overbooking, incorporando la probabilidad de cancelación en la planificación de ocupación.

Empezar con acciones poco invasivas, ya que existen falsos positivos y en TEST se señala aproximadamente el 53 % de las reservas.

**FIN DE LA
PRESENTACIÓN**

**MUCHAS
GRACIAS**