

Factores asociados a los ingresos por ventas: análisis descriptivo y regresión lineal múltiple

Máster de Data Science · Módulo de Estadística

1. Objetivo y pregunta de investigación

El objetivo es identificar qué factores de marketing, comportamiento del cliente, engagement digital y contexto comercial están más asociados con los ingresos por ventas. La variable dependiente es `sales_revenue_usd` y el análisis se plantea en términos de asociación, no de causalidad.

Pregunta de investigación: ¿Qué factores están más asociados con unos mayores ingresos por ventas?

2. Datos y variables

Se analiza un dataset sintético de 60.000 observaciones y 23 variables, correspondiente al periodo 2020–2023. El campo `región` representa siete mercados/localizaciones (Cairo, Riyadh, Dubai, Alexandria, Kuwait, Amman y Casablanca); por tanto, no se interpreta como una variable homogénea de países. El identificador `id` y la fecha se excluyen del modelo principal.

Bloque	Variables consideradas
Marketing	Presupuesto, promociones y descuentos
Cliente	Segmento, edad, satisfacción y compras previas
Digital / engagement	Tráfico web, conversión, email y seguidores
Contexto comercial	Región, canal, categoría, temporada, vendedores y competencia

3. Metodología

El análisis sigue un flujo breve y reproducible: revisión de calidad; estadística descriptiva de variables numéricas y categóricas; detección de outliers mediante IQR; visualización de relaciones; selección de variables evitando redundancias; regresión lineal múltiple con división 80/20 entre entrenamiento y test; evaluación con R^2 , MAE y RMSE; y diagnóstico mediante VIF, residuos y test de White.

4. Estadística descriptiva y calidad de los datos

No se detectaron duplicados exactos ni valores imposibles en las reglas revisadas. Cuatro variables presentan alrededor de un 3 % de nulos (satisfacción, días desde última compra, descuento y tasa de apertura de email). Se conservan durante la descriptiva y se imputan con

la mediana únicamente para la regresión, ya que esta medida es menos sensible a valores extremos.

Variable	Media	Mediana	Desv. típica	Asimetría	Curtosis*
Ingresos (USD)	5.911	4.340	5.842	6,63	105,03
Presupuesto marketing	10.032	4.922	17.300	7,46	102,94
Conversión	0,09	0,08	0,06	1,12	1,54
Satisfacción	3,50	3,50	0,87	0,01	-1,19
Compras previas	4,99	5,00	2,23	0,44	0,17

**Curtosis expresada como exceso de curtosis de Pandas: una distribución normal toma valor 0.*

Los ingresos presentan una distribución claramente asimétrica a la derecha: la media (5.911 USD) supera a la mediana (4.340 USD), la asimetría es 6,63 y el máximo alcanza 190.377 USD. Esto indica que la mayor parte de las observaciones se concentra en niveles moderados, mientras que un pequeño grupo registra importes excepcionalmente altos. La fuerte curtosis confirma la presencia de colas pesadas y valores extremos.




Figura 1. Distribución y boxplot de los ingresos por ventas.

Mediante el criterio IQR se identifican 3.816 outliers en sales_revenue_usd, equivalentes al 6,36 % de la muestra. No se eliminan porque no son valores imposibles y pueden representar operaciones comerciales legítimas. Esta decisión preserva información relevante, aunque anticipa que los casos extremos pueden deteriorar algunos supuestos del modelo.

5. Relaciones entre variables y patrones empresariales

Las variables categóricas muestran diferencias descriptivas claras. Corporate registra un ingreso medio de 10.676 USD frente a 3.421 USD en New; Electronics alcanza 7.972 USD

frente a 4.647 USD en Food & Beverage; y Q4 alcanza 7.549 USD frente a 4.746 USD en Q1. En cambio, las diferencias entre regiones son reducidas. Estas comparaciones son descriptivas y todavía no controlan simultáneamente el resto de factores.




Figura 2. Ingreso medio por segmento, canal, categoría de producto y temporada.

Entre las variables numéricas, `marketing_budget_usd` presenta la correlación lineal más alta con `revenue` ($r = 0,727$). El gasto online ($r = 0,70$) y offline ($r = 0,68$) también se relacionan con los ingresos, pero su correlación con el presupuesto total es muy elevada (0,95 y 0,93, respectivamente). Para evitar redundancia y multicolinealidad, el modelo principal utiliza el presupuesto total y excluye sus dos componentes.




Figura 3. Relación entre presupuesto de marketing e ingresos.

Otras variables, como `conversion_rate`, `compras previas` o `satisfacción`, presentan correlaciones simples pequeñas. Esto no implica que carezcan de utilidad: la correlación

estudia dos variables de forma aislada, mientras que la regresión múltiple estima la asociación de cada factor manteniendo constantes los demás.

6. Regresión lineal múltiple

El modelo se ajusta sobre 48.000 observaciones de entrenamiento (80%) y se evalúa con 12.000 observaciones de test (20%). Las variables categóricas se transforman en $k-1$ dummies. Las categorías de referencia relevantes son Corporate (segmento), Direct Sales (canal), Clothing (producto) y Q1 (temporada). La interpretación de cada coeficiente es ceteris paribus: manteniendo constantes las demás variables.

Variable	Coef.	Interpretación
Marketing budget	+0,245	+245 USD de revenue por cada 1.000 USD adicionales de presupuesto
Conversion rate	+4.059	+40,6 USD por +1 punto porcentual de conversión
Compras previas	+134,4	+134 USD por cada compra anterior adicional
Satisfacción	+257,8	+258 USD por cada punto adicional
Segmento New	-7.295,8	Diferencia frente a Corporate
Wholesale	+1.665,4	Diferencia frente a Direct Sales
Electronics	+2.937,7	Diferencia frente a Clothing
Q4	+2.762,0	Diferencia frente a Q1

Los coeficientes anteriores son estadísticamente significativos ($p < 0,001$). En términos empresariales, los resultados muestran que el presupuesto de marketing mantiene una asociación positiva con los ingresos incluso después de controlar por cliente, canal, producto y temporada. También destacan la mayor recurrencia de compra, la satisfacción y la conversión. Por el contrario, variables como edad, seguidores, tasa de apertura de email y región no presentan evidencia estadística clara una vez controlado el resto.

7. Evaluación y diagnóstico del modelo

Métrica	Resultado	Interpretación
R^2 train	0,834	Explica el 83,4 % de la variabilidad en entrenamiento
R^2 ajustado	0,833	Muy próximo al R^2 ; no mejora artificialmente por añadir variables
R^2 test	0,831	Mantiene un rendimiento muy similar en datos nuevos
MAE test	1.247 USD	Error absoluto medio de predicción
RMSE test	2.361 USD	Mayor que MAE por la presencia de errores extremos

La proximidad entre R^2 de entrenamiento y test no sugiere sobreajuste fuerte. El VIF máximo es 2,18, por debajo de 5, por lo que no aparece multicolinealidad seria. Sin embargo, los residuos son muy asimétricos y el test de White resulta significativo ($p < 0,001$), indicando heterocedasticidad. Se utilizan errores estándar robustos HC3; las conclusiones principales mantienen su significatividad. Se probó además una transformación logarítmica como comprobación, pero se conserva el modelo en niveles por su interpretación directa en USD.

8. Conclusiones

El análisis muestra que los ingresos están asociados con una combinación de inversión comercial, características del cliente y contexto de venta. El presupuesto de marketing es la variable numérica con mayor asociación directa con revenue y mantiene un efecto positivo en la regresión. Además, Corporate/VIP, Electronics, Wholesale y Q4 presentan los mayores niveles de ingreso o diferencias positivas frente a sus categorías de referencia. La recurrencia, satisfacción y conversión también aportan capacidad explicativa.

El modelo presenta un buen rendimiento: **R^2 test = 0,831, MAE = 1.247 USD y RMSE = 2.361 USD**. La diferencia entre MAE y RMSE refleja algunos errores elevados, coherentes con los valores extremos observados.

9. Recomendaciones empresariales

- Priorizar el seguimiento del presupuesto de marketing y la tasa de conversión, ambos asociados positivamente con revenue.
- Diseñar estrategias diferenciadas por segmento, categoría, canal y temporada, especialmente en Corporate/VIP, Electronics, Wholesale y Q4.
- Utilizar recurrencia y satisfacción como indicadores complementarios de valor, sin interpretar estas asociaciones como causalidad.

10. Limitaciones

- El dataset es sintético, por lo que los resultados no son directamente generalizables a una empresa real.
- El análisis es observacional: identifica asociaciones, no causalidad.
- Existen outliers, heterocedasticidad y residuos no normales; los errores robustos mejoran la inferencia, pero persisten limitaciones en casos extremos.

Conclusión final: en este caso de estudio, el presupuesto de marketing y el contexto comercial —especialmente segmento de cliente, categoría, canal y temporada— son los factores más relevantes para explicar los ingresos; la recurrencia, satisfacción y conversión añaden información adicional.